华南师范大学本科生毕业论文（设计）中期报告

<table>
<tr><td>学院</td><td>计算机学院</td><td>专业</td><td>计算机科学与技术</td><td>班级</td><td>22级计科2班</td></tr>
<tr><td>姓名</td><td>沈佳彤</td><td>学号</td><td>20212821037</td><td>指导教师姓名及职称</td><td>曹阳</td></tr>
<tr><td colspan="3">毕业论文(设计)题目</td><td colspan="3">基于大模型的商务合同关键条款智能解析系统</td></tr>
<tr><td>简述开题以来所做的具体工作和取得的进展或成果</td><td colspan="5">自开题以来，按照既定的研究计划推进，已完成第一阶段“文献调研与方案设计”的全部任务，并顺利进入第二阶段“系统核心模块开发”，完成了部分核心基础模块的搭建与初步实现。研究工作取得以下进展：
1. 第一阶段成果：方案设计与技术准备
(1) 文献深化与技术选型确认：
在开题报告基础上，进一步研读了关于大语言模型提示工程、RAG 高级策略（如多路检索、查询重写）以及 Neo4j 知识图谱应用的前沿文献。明确了采用 DeepSeek-R1 作为基座大模型，明确了以 React + Next.js 和 FastAPI + Python 为核心的开发栈。
领域知识结构化工作：
对《中华人民共和国民法典》合同编等核心法规进行了条款梳理与分解。
(2) 系统详细设计：
完成了数据库 ER 图设计，定义了 MySQL 中合同、用户等数据表结构，以及 Neo4j 中“法律条文”、“合同主体”、“义务”、“风险类型”等实体与关系的初步图谱模型。
完成了主要 API 接口的初步设计。
2. 第二阶段进展：核心模块开发
(1) 前后端基础框架与核心服务层搭建：
前端 (React/Next.js)：已完成项目基础框架搭建，集成 Ant Design 和 ECharts 库。完成了首页展示页面（含数据仪表盘原型）和知识图谱界面的骨架开发，为可视化展示做好准备。
后端 (FastAPI)：已完成主服务框架，配置好 CORS、依赖注入等。基于 Pydantic 完成了核心 API（文件上传、解析请求、报告生成）的请求/响应模型定义。
(2) 关键业务模块实现：
文档处理模块：利用 pytesseract 和 PIL 库，实现了对 JPG/PNG 等图像格式合同的高质量中英文 OCR 识别；利用 python-docx 库完善了 Word 文档的文本与基础样式提取。已封装为统一的文档预处理服务。
双数据库系统：
MySQL 业务库：通过 SQLAlchemy ORM 完成了数据库模型定义（合同、用户、分析记录等）与表结构创建，实现了基础数据持久化。
Neo4j 知识图谱：使用 py2neo 开发了数据注入脚本，已将《民法典》合同编核心法条作为“法律节点”连同其“约束”、“关联”等关系导入图数据库，完成了领域知识库的初步构建与数据注入。</td></tr>
</table>

(3) 基于技术路线的 RAG 核心引擎实现：

检索服务：自主实现了文本分块、向量化（使用 OpenAI Embeddings API）与向量存储（ChromaDB）流程。同时，通过 py2neo 实现了基于 Cypher 查询的知识图谱检索，为混合检索奠定基础。

增强与生成服务：自主开发了 RAG 编排器，负责协调上述检索、结果融合及 Prompt 组装。已针对“合同类型判断”、“关键信息提取（双方、金额、期限等）”、“基础风险预警”等任务，设计并调试了系列 Prompt 模板。

大模型集成：通过 openai 库稳定接入 DeepSeek-R1 API，并已将 RAG 引擎与大模型调用无缝集成，形成了从“文档输入”到“增强解析”的基本闭环。

(4) 前后端核心功能界面初步联通：

前端：已完成“文件管理界面”的核心功能，支持合同文件的上传、列表展示与筛选。

后端：已开发对应的文件上传、解析任务触发等核心 API 接口。

联通测试：前后端已成功联通，能够实现用户从前端上传合同文件，后端接收后启动 OCR、RAG 增强解析流程，并将初步的结构化结果（如提取出的合同类型、当事人信息）返回前端进行展示。

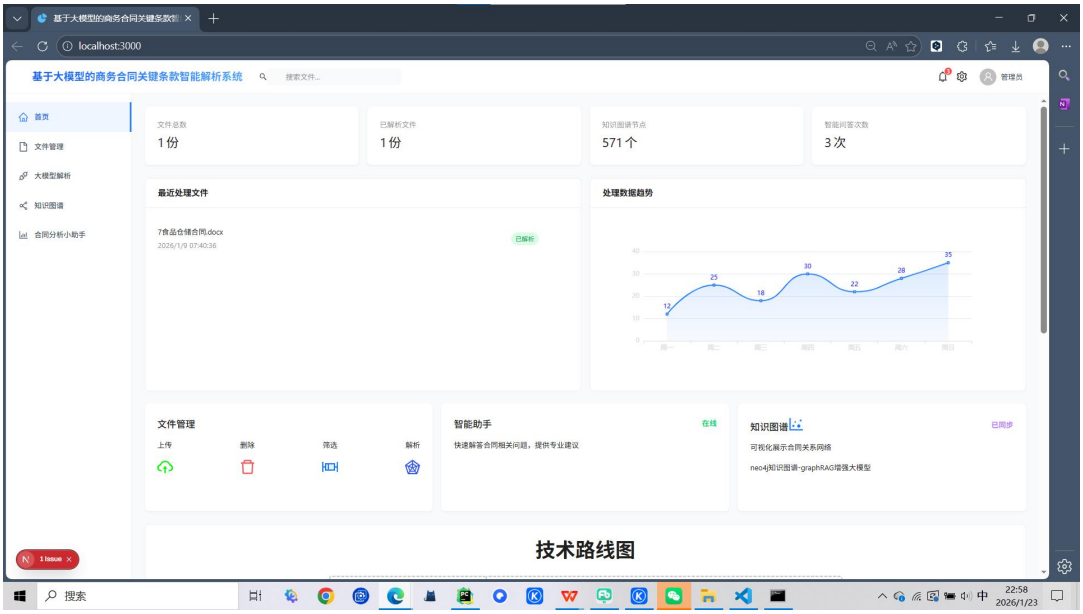

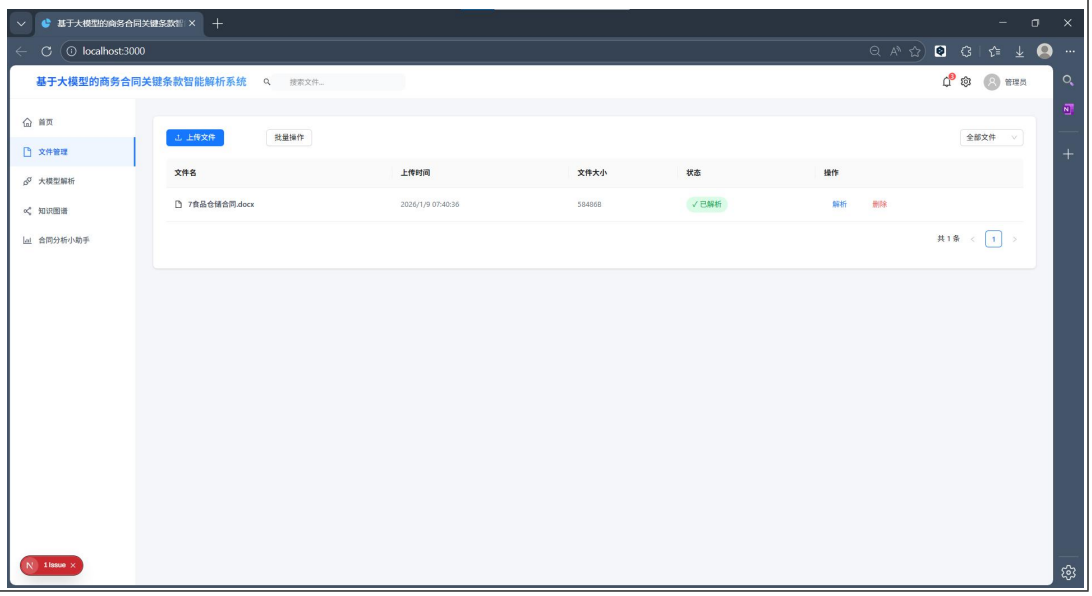

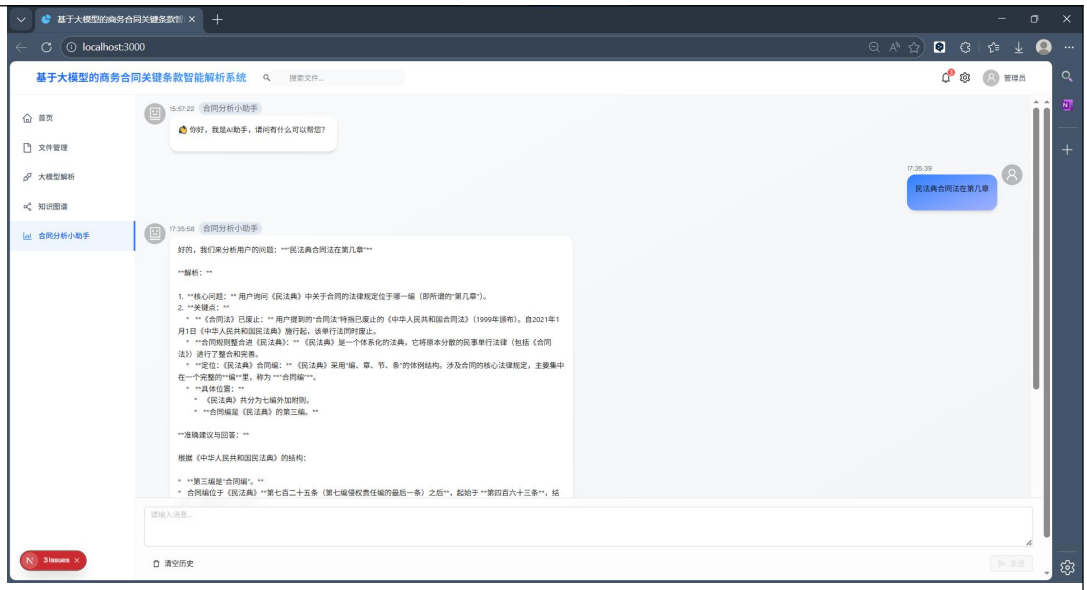
基于大模型的商务合同关键条款智能解析系统
localhost:3000
首页
文件管理
大模型解析
知识图谱
合同分析小助手
15:57:22 合同分析小助手
你好，我是AI助手，请问有什么可以帮您？
17:35:39
民法典合同法在第几章
17:35:58 合同分析小助手
好的，我们来分析用户的问题：***民法典合同法在第几章***
解析：
1. **核心问题：** 用户询问《民法典》中关于合同的法律规定位于哪一编（即所谓的"第几章"）。
2. **关键点：**
* **《合同法》已废止：** 用户提到的"合同法"特指已废止的《中华人民共和国合同法》（1999年颁布）。自2021年1月1日《中华人民共和国民法典》施行起，该单行法同时废止。
* **合同规则整合进《民法典》：** **《民法典》是一个体系化的法典，它将原本分散的民事单行法律（包括《合同法》）进行了整合和完善。
* **定位：《民法典》合同编：** **《民法典》采用"编、章、节、条"的体例结构。涉及合同的核心法律规定，主要集中在一个完整的**"编"**里，称为 ***"合同编"***。
* **具体位置：**
* 《民法典》共分为七编外加附则。
* **合同编是《民法典》的第三编。**
准确建议与回答：
根据《中华人民共和国民法典》的结构：
* **第三编是"合同编"。**
* 合同编位于《民法典》**第七百二十五条（第七编侵权责任编的最后一条）之后**，起始于 **第四百六十三条**，结
请输入消息...
清空历史
3 Issues

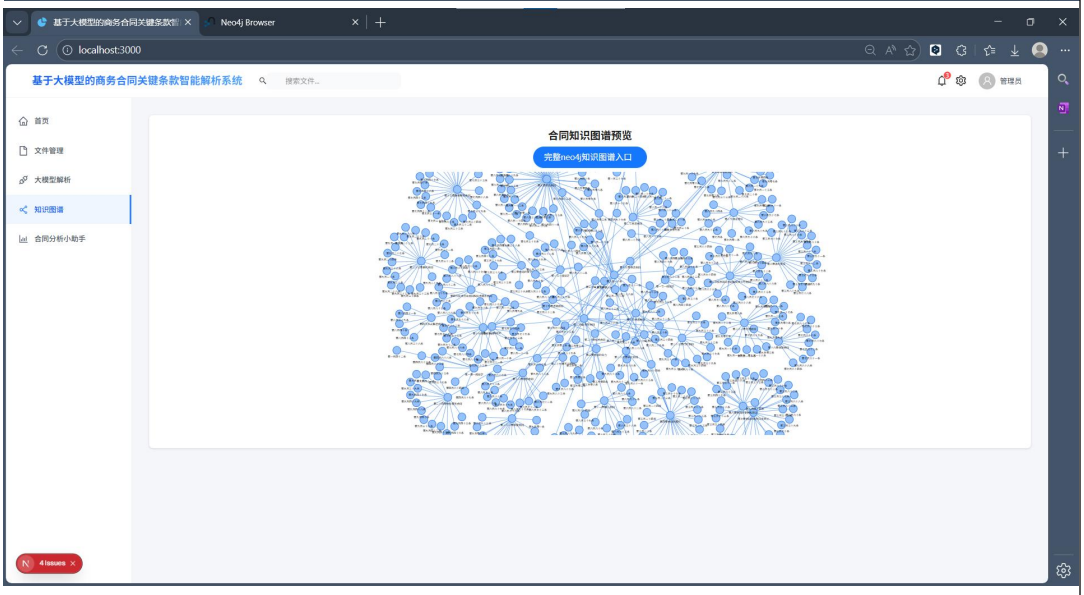
基于大模型的商务合同关键条款智能解析系统
Neo4j Browser
localhost:3000
首页
文件管理
大模型解析
知识图谱
合同分析小助手
合同知识图谱预览
完整Neo4j知识图谱入口
4 Issues

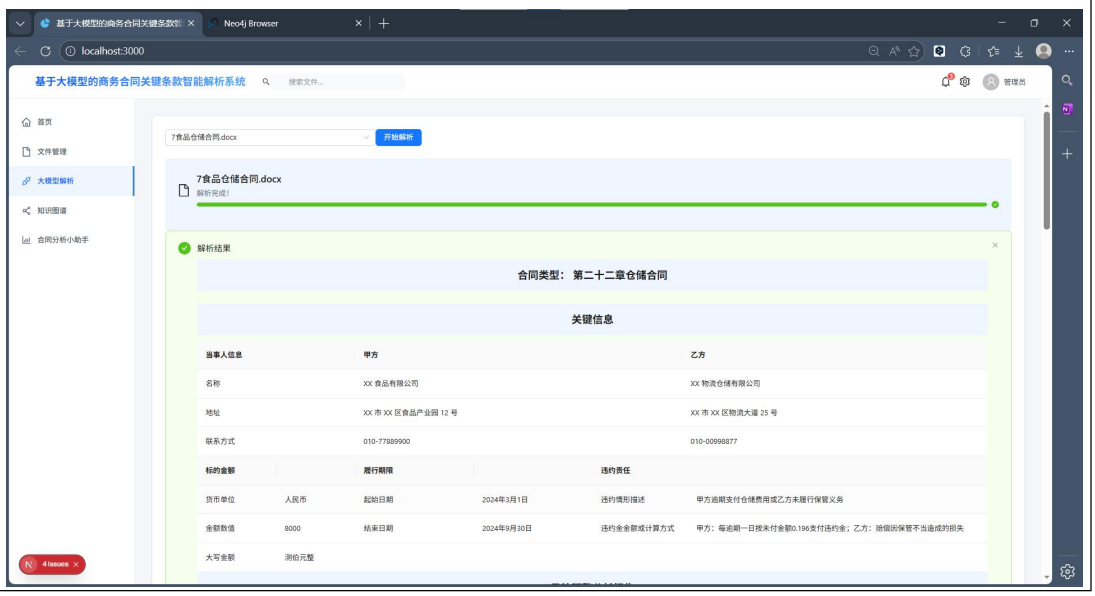
基于大模型的商务合同关键条款智能解析系统
Neo4j Browser
localhost:3000
首页
文件管理
大模型解析
知识图谱
合同分析小助手
7食品仓储合同.docx
开始解析
7食品仓储合同.docx
解析完成！
解析结果
合同类型：第二十二章仓储合同
关键信息
当事人信息 甲方 乙方
名称 XX 食品有限公司 XX 物流仓储有限公司
地址 XX 市 XX 区食品产业园 12 号 XX 市 XX 区物流大道 25 号
联系方式 010-77889900 010-00998877
标的金额 履行期限 违约责任
货币单位 人民币 起始日期 2024年3月1日 违约情形描述 甲方逾期支付仓储费用或乙方未履行保管义务
金额数值 8000 结束日期 2024年9月30日 违约金金额或计算方式 甲方：每逾期一日按未付金额0.196支付违约金；乙方：赔偿因保管不当造成的损失
大写金额 捌佰元整
4 Issues

存在的具体问题	1．当前采用的自主开发模式需要自行实现大量"胶水代码"，如文本分块、检索排序、流程编排等，随着功能复杂度增加，各模块间的协调和错误处理变得更加复杂，迭代难度高，计划使用 LangChain 框架简化 RAG 流程开发。 2．缺失来自公开渠道的典型商务合同范本（如采购、技术开发、服务合同）及专家审查意见，需进一步收集提炼出核心风险点及其判断依据。 3．知识图谱体量小，目前构建的知识图谱主要以《民法典》合同编为主干，对于大量部门规章、行业标准合同范本以及鲜活的司法判例要点，覆盖尚不全面。知识库的更新目前依赖手动脚本导入，缺乏一个可持续、半自动化的知识获取与更新流程设计。 4．当前实现的基于向量相似度的检索，在处理法律条文等高度专业化文本时，存在“语义匹配但法律适用不匹配”的情况。而且目前还未正确评估该智能解析系统生成结果的可靠性，DeepSeek-R1 在自由文本生成上表现优异，但在严格遵循指令输出稳定、无冗余、可直接入库的 JSON 结构时，仍会出现格式偏差、内容遗漏或额外解释。
下一步工作计划与安排	1．引入 LangChain 重构核心引擎：使用 LangChain 的 DocumentLoaders, TextSplitters, VectorStores, Chains 等组件重构现有 RAG 流程，大幅减少“胶水代码”，提升模块化程度与可维护性。 2．系统性扩充知识库：集中收集至少 5 类（采购、技术服务、租赁、委托、劳务）的公开标准合同范本及对应的官方合同示范文本使用指南；从“中国裁判文书网”等渠道筛选并抽取与上述合同类型相关的典型司法判例要点（争议焦点、裁判要旨）。 3．开发混合检索器：在 LangChain 框架下，实现一个 HybridRetriever，将向量检索（语义相似度）、关键词检索（如 BM25，用于精确匹配法条编号）和 Neo4j 图谱查询（用于查询实体间关系）的结果进行融合与重排序。 4．设计检索评估实验：构建一个小型测试集（约 50 个合同条款查询），人工标注最相关的知识条目，用于评估混合检索相较于纯向量检索在召回率和准确率上的提升。 5．优化提示工程：采用 Pydantic Output Parser 或 Structured Output 提示技术，强制要求模型以指定 JSON Schema 输出，并加入思维链(CoT)引导其分步骤推理。 6．构建健壮的后处理管道：开发一个解析-清洗-验证流水线，对模型输出进行：格式校验、缺失字段智能填充、冗余信息过滤，并记录解析失败案例用于后续 Prompt 迭代。 7．设计并执行端到端评估：构建一个涵盖不同合同类型、不同风险点的基准测试集，定义评估指标（关键信息抽取的准确率/召回率/F1，风险识别准确率，幻觉率等），量化系统性能。 8．探索知识库半自动更新：设计一个简易的“知识摄入”流程，允许上传新的法规 PDF，自动进行文本提取、关键实体/关系抽取（可借助大模型），经人工审核后一键更新至知识库。

指 导 教师意见	指导教师： 审阅时间：