华南师范大学本科毕业论文（设计）开题报告

学院	计算机学院	专业	计算机科学与技术	班级	计科2班
姓名	沈佳彤	学号	20212821037	指导教师姓名及职称	曹阳
毕业论文（设计）选题		基于大模型的商务合同关键条款智能解析系统			

（一）选题目的与意义：

2021 年 1 月 1 日，《中华人民共和国民法典》正式施行，根据民法典第四百六十四条规定，合同是民事主体之间设立、变更、终止民事法律关系的协议。合同是平等组织之间互相约束权利义务的协议，能够起到规范市场行为，保护经济秩序的重要作用。然而，据相关统计显示，我国合同的履行状况并不理想，大多数的企业都曾陷入到合同纠纷当中。因此，加强合同风险评估不仅能够帮助企业维护合法权益而且能够保护市场经济体系的有序运行。合同的客观风险是法律法规，对合同文本进行法律风险评估，判断文中语句的逻辑性以及完整性有助于避免法律纠纷，完善责任体系。

随着互联网的发展和电子合同的普及，合同风险审查应用的前景和需求也逐渐凸显，然而，目前的审查过程中，风险识别主要依靠于人工进行，这种高度依赖专家经验的方式不仅缺乏效率，也容易产生误判。因此，迫切需提升工程合同风险识别的自动化与智能化程度。

1.选题目的

本选题《基于大模型的商务合同关键条款智能解析系统》旨在针对传统合同审查效率低、成本高的问题，探索一条基于大型语言模型 API 的轻量化、高效率解决方案。本研究不追求从零开始训练模型，而是专注于如何通过智能提示工程与检索增强生成技术，将通用大模型安全、可靠地应用于专业的商务合同分析领域。具体目的如下：

（1）实现关键条款的精准提取与结构化输出：核心目的是设计一套高效的提示词模板与数据解析流程，利用大语言模型强大的自然语言理解能力，从复杂的非结构化合同文本（兼容 PDF/Word 格式）中，自动抽取出“当事人”、“标的金额”、“履行期限”、“违约责任”等核心要素，并将其转化为规整的 JSON 或表格等结构化数据，为后续的数字化管理奠定基础。

（2）构建基于外部知识库的风险预警机制：为避免大模型的“幻觉”问题并确保专业准确性，本研究将构建一个轻量级的商务合同领域知识库（如《民法典》合同编要点、常见风险条款范本等）。通过检索增强生成技术，在模型分析合同时，动态地为它提供相关法律依据，引导其进行风险判断，最终生成附有依据的、可视化的风险提示报告。

（3）验证一种低成本的垂直领域 AI 应用范式：本研究旨在证明，通过巧妙地组合 Prompt 工程、RAG 技术与现有 LLM API，无需耗费巨资进行模型训练，也能构建出满足专业场景需求、输出稳定可信的智能应用系统。这为中小企业低成本引入 AI 能力提供了有价值的实践参考。

2.选题意义

在理论意义层面：

（1）为垂直领域大模型应用提供轻量化范式：本研究深入探索了如何在不改动模型底层参数的情况下，通过“外部知识”与“指令引导”这两个外部手段，有

效约束和增强通用大模型在专业领域（法律合同）的表现。这为如何安全、可控地利用大模型提供了重要的工程实践案例。

（2）深化提示工程在复杂任务中的方法论：合同解析是一个需要多步骤推理的复杂任务。本研究通过设计“识别->提取->分析”的思维链提示，系统地引导模型进行逻辑推理，是对复杂提示策略设计与应用的一次有益探索和验证。

在实践意义层面：

（1）极大提升合同处理效率，降低人力成本：本系统能够自动化完成合同初审中最繁琐的信息提取与基础风险筛查工作，将法务与商务人员从重复性劳动中解放出来，专注于高阶决策，显著提升工作效率，尤其适合海量合同初筛、内部审计等场景。

（2）有效降低因人为疏漏导致的合规风险：系统具备不知疲倦、标准统一的优势，可以规避人工审查中因疲劳、经验差异造成的疏漏，确保每一份合同都经过相同标准的风险扫描，为企业筑牢合规防线。

（3）推动 AI 技术的普惠化与实用化：本研究采用基于 API 的轻量化技术路线，极大地降低了技术门槛和开发成本，证明了先进 AI 技术并非大公司的专属。这对于推广 AI 技术在广大中小型企业及传统行业的应用，具有积极的示范意义。

（二）研究现状与文献综述：

随着企业数字化进程的加速，商务合同的数量与日俱增，其智能审查与解析需求日益迫切。合同审查的核心任务之一，即对合同中的关键条款进行识别、分类与解析，其技术演进与自然语言处理(Natural Language Processing, NLP)，特别是文本分类技术的发展脉络紧密契合。文本分类是指在给定分类体系下，通过特定模型计算，为输入文本指定预定义标签的过程，是自然语言处理(NLP)中应用最广泛、也是最重要的领域之一[1]。本节将从文本分类技术的宏观发展入手，详细阐述其在合同审查领域的具体应用与实践，从而厘清技术驱动下合同关键条款解析的研究轨迹与发展趋势。

2.1 基于传统机器学习的文本分类与合同审查的自动化萌芽

传统机器学习方法在文本分类领域的发展，为合同审查的早期自动化研究奠定了技术基础。其演进脉络呈现出从“机械匹配”到“规则推理”，再到“统计学习”的清晰路径。

早期研究主要依赖于基于关键词匹配的机械方法[2][3],效果十分有限。为提升准确性，研究者转向知识工程方法[4]，即借助专业人员定义大量推理规则进行分类。该方法虽提升了准确度，但难以应对互联网时代数据的爆炸式增长，且其性能极易受人为因素制约。随后，机器学习方法逐渐成为主流，通过使机器自动学习文本特征实现分类自动化[5]，显著提高了结果的客观性与可靠性。在 1960 年至 2010 年间，传统机器学习主导文本分类领域，形成了一套典型流程，包括文本预处理、特征提取（如词袋模型[6]、TF-IDF[7]）和分类器计算（如朴素贝叶斯(Naive Bayes, NB)[8]、K 近邻(K-Nearst Neighbor, KNN)[9]、支持向量机(Support Vector Machines, SVM)[10]）。尽管这些方法在准确性与稳定性方面表现良好，但其局限性亦十分突出：高度依赖耗时费力的特征工程、领域适应性较差，且难以有效捕捉文本的序列结构、上下文信息及深层语义，与人类语言理解机制存在明显差距。

在此技术背景下，合同审查的自动化研究开始萌芽。 研究者们将传统文本分类模型应用于法律领域，把风险条款检测、合同类型判断等任务形式化为分类问题。例如，例如，Gao X 等人（2011）[11]提出了一种无监督的信息提取方法，用于检测

服务合同异常；Chalkidis I 等人（2017）[12]则对比了逻辑回归和支持向量机等分类器，发现结合人工规则的模型在合同实体提取上效果最佳；Lippi M 等人（2019）[13]同样利用 SVM 等模型，将风险条款检测视为文本分类任务。这一阶段的探索，证实了利用算法自动识别合同风险的可行性，但其性能同样受限于传统方法的瓶颈——高度依赖特征工程质量，且对法律文本复杂的语义和逻辑关系缺乏深层理解。

2.2 基于深度学习的文本分类与合同理解的初步深化

深度学习的突破性进展为文本分类带来了范式转变。相较于传统机器学习方法，深度学习通过深层神经网络自动挖掘文本的深层语义特征，避免了繁琐的人工特征工程，并能有效融合多模态信息以提升分类准确性[14]。其核心在于表征学习，能够将文本映射为蕴含丰富语义的低维连续向量。

在模型架构层面，卷积神经网络(Convolutional Neural Networks, CNN)与循环神经网络络(Recurrent Neural Network, RNN)的广泛应用，使模型能够自动学习文本的层次化特征，有效提升了对序列信息和局部语义的捕捉能力[15][16]。 国内学者也在此领域进行了深入探索，如彭玉青等人[17]通过融合 CNN 与 LSTM 处理长文本依赖问题，韩涛等人[18]则创新性地结合 CNN 与 XGBoost 以提升分类性能，这些研究共同推动了中文文本分类技术的发展。

深度学习模型为合同审查带来了“理解”的维度。其强大的表征学习能力，使得对合同进行更细粒度的分析成为可能。研究者们开始采用更先进的神经网络架构。在国内司法领域，张虎等人[19]提出使用卷积神经网络(Convolutional Neural Networks, CNN)或循环神经网络(Recurrent Neural Network, RNN)通过概率相加的办法进行多模型融合，提取司法文书中事件内容的描述部分的特征，再根据法律文书内容进行相关法条推荐；王文广等人[20]提出将 HAC(hybrid attention and CNN model，混合深度神经网络模型)应用于法律文书的智能化处理等方法。这些研究虽未直接针对商务合同，但其技术路径清晰地表明，深度学习模型能够支持对合同条款——而不仅仅是整个文档——进行更深层次的语义分析与要素提取，从而推动了合同审查从“文档级”分类向“条款级”理解的实质性演进。

2.3 基于预训练模型的文本分类与合同解析的效能跃升

表征学习技术经历了从静态词向量到动态上下文表征的关键演进，开启了预训练的新范式。2013 年 Google 提出的 word2vec[21]模型开创了基于上下文的词向量表示方法，将非结构化文本转化为可计算的稠密向量。随后，2018 年提出的 ELMo[22]模型基于多层双向 LSTM 网络，实现了对词汇复杂特征及其语境动态变化的深度建模，显著提升了词表示的准确性和丰富性。

Transformer 架构[23]的提出标志着神经网络在自然语言处理领域的重大进展，展，它摒弃了传统的循环神经网络（RNN）和长短期记忆网络（LSTM）结构，采用了全新的架构。此类模型在海量语料上学习到的通用语言知识，通过下游任务的微调，能够在诸多 NLP 任务上取得突破性进展。王梓涵等人[24]提出的 Bi-FLEET 模型和朱鑫海[25]基于 RoBERTa 的合同要素抽取研究，正是这一范式在合同解析领域的成功实践。Elwany E 等人（2019）[26]直接微调 BERT 以检测合同中的到期时间与自动续订条款，取得了远超前代方法的性能。这标志着合同解析技术进入了“要素级”抽取的新阶段，能够以更高的准确率定位和分类具体的合同元素。

2.4 大语言模型与合同智能解析的新范式：提示学习与知识增强

生成式语言模型（Generative Language Model，GLM）是一种在给定前文单词的情况下预测文本序列中一下个单词的深度学习技术。这些模型根据给定的神经网络结构，可以从大量的文本数据中学习一个单词在给定一组单词后出现的条件概

率，并使用这些概率生成具有意义且连贯性高的文本。

近年来，由于数据量的增加和计算能力的提升，以往的 GLM 取得了革命性的突破，催生出了一大批拥参数规模更大的语言模型，即大语言模型（Large Language Model，LLM），这一进展极大地影响了 NLP 领域的范式。

2.4.1 大语言模型的能力与局限

以 GPT 系列为代表的大语言模型（LLM）凭借其基于 Transformer 的架构和海量文本训练，展现出卓越的通用任务处理能力。这些模型不仅在阅读理解、文本生成、 机器翻译等传统 NLP 任务上表现出色，还可以通过少样本学习处理更复杂的任务，例如逻辑推理、理解隐含含义和解决数学问题等[27]，在某些专业测试中甚至达到了与人类专家相当的水平。

然而，当这些大语言模型直接部署应用于特定的垂直领域时[28][29]，如工程合同管理领域[30]，其局限性便凸显出来。首先，模型存在知识更新缓慢的问题，如 ChatGPT 3.5 的知识截止到 2021 年 9 月，无法获取最新的法律法规信息。更重要的是，模型会产生"幻觉"现象——生成看似合理但缺乏事实依据的内容[31]。这种幻觉按其性质可分为内在幻觉（输出与输入冲突）和外在幻觉（输出无法验证），其成因涉及数据、训练和推理三个层面[32]。在工程合同风险识别这种知识密集且逻辑严谨的领域，幻觉问题的影响是致命的，这也正是大语言模型尚未在法律等专业领域得到广泛应用的重要原因。

2.4.2 知识增强的技术路径

为缓解大语言模型的幻觉问题，当前研究主要沿着两大技术路径展开：知识编辑（Knowledge Editing） 与 知识增强（Knowledge Augmentation）[33]。知识编辑旨在直接修改模型内部的知识体系，而知识增强则强调在模型推理时引入外部知识源。

1. 知识编辑：内部知识的直接修正

知识编辑通过对已训练好的模型内部知识表示进行直接修改，以实现知识的更新、修正或注入。根据技术手段的不同，可进一步划分为模型编辑（Model Editing）与输入编辑（Input Editing）[34][35]。

（1）模型编辑是指对已经训练好的模型进行后续的调整或优化，以改善性能、适应新数据或纠正偏差。这是一种通过参数化知识来适配特定领域、解决“幻觉”的直接方法。其主流模式可分为两类：

①修改模型参数：此类方法直接定位并更新模型中与特定知识相关的参数。它又可细分为：a. 定位编辑：以细粒度定位并修改知识对应的参数。例如，Meng 等[36]利用因果追踪定位 Transformer 模型中前馈层与事实知识关联的参数，实现精确编辑；Dai 等[37]则通过知识神经元细化技术，检测并操纵与特定事实相关的神经元来更新知识。b. 元学习：其核心是让模型学会如何快速学习编辑自身所需的参数。例如，De Cao 等[35]提出的知识编辑器利用超网络预测权重更新；Mitchell 等[38]则通过梯度分解模型编辑器网络，学习如何转换语言模型的梯度以优化编辑效果。在法律等领域，Lawyer LLaMA[39]和 ChatLaw[40]等项目正是通过此类微调方法向 LLaMA 模型注入法律知识，克服了模型在特定领域应用中的缺陷。

②保留模型参数：此类方法不直接改动原有模型参数，而是通过外部扩展来集成新知识。a. 基于内存（Memory-based）的方式：将知识存储在外部内存结构中，通过检索器提取相关信息来指导模型生成。例如，Mitchell 等[41]提出的反事实模型编辑方法利用显式内存存储编辑内容；Zhong 等[42]与 Zheng 等[43]则通过用编辑过的事实和从记忆库中检索的示例来提示模型。b. 附加参数（Parameter-expansion）的

方式：通过引入额外的可训练参数（如新的网络层或神经元）来扩展模型。例如，Huang 等[44]提出的 T-Patcher 为特定错误训练一个仅在相关输入时激活的神经元；Dong 等[45]则通过新增一个校准知识神经元串联到模型最后一层，将其输出作为调整项来修正事实知识。

（2）输入编辑则绕过对模型参数的复杂操作，直接对输入数据进行优化和构建，以最低成本和最高便利性向 LLM 注入知识或引导其行为[33][43]。其广义目标是通过提高输入数据质量来提升模型输出的准确性与相关性。提示工程（Prompt Engineering） 是输入编辑的典型实例，其核心在于如何有效构造输入，以引导模型生成期望的输出。得益于 LLM 的强大性能，提示工程发展出多种高级策略，旨在激发模型的逐步推理与复杂思维能力，如：①思维链（Chain-of-Thought, CoT）：通过提供逐步推理示例，引导模型将复杂问题分解为多个子步骤进行推理[46]。②零样本思维链（Zero-shot-CoT）：在零样本环境下，使用如“让我们逐步地思考”等触发短语直接激发模型的多步推理能力[47]。③思维树（Tree-of-Thoughts, ToT）：允许模型同时探索多条推理路径，形成树状思维结构，通过评估和回溯做出全局决策[48]。④自我一致性（Self-consistency）：基于“多推理路径结果一致则答案更可靠”的理念，采样多条推理路径并选择最一致的答案[49]。⑤思维图谱（Graph of Thoughts）：将 LLM 生成的信息单元及其依赖关系建模为图，通过协同与反馈循环增强推理[50]。⑥递增式提示：依据递增学习理论，将复杂问题分解为从简到难的子问题依次解决[51]。

尽管知识编辑技术能有效提升模型知识的准确性、相关性和时效性，但其在实际业界广泛应用仍面临挑战。模型编辑虽能内化知识，适用于需要特定结构或格式的场景，但存在调优难度大、计算成本高、可解释性差等问题，且难以快速迭代新知识，面对未知领域仍有产生“幻觉”的风险。输入编辑则高度依赖对模型工作方式的深入理解，且当模型本身存在知识盲区时，提示设计也难以根本克服错误输出。

2. 知识增强：外部知识的动态引入

知识增强方法的本质，是从外部数据源为模型提供额外的信息输入，以弥补其内部知识的不足，从而提高模型的理解与生成能力。因此，如何高效、准确地检索并提供相关信息，便成为此技术路径的核心。当前，检索增强生成（Retrieval-Augmented Generation, RAG） 是该领域中最受关注的知识增强手段。

RAG 的概念最初由 Lewis 等[52]提出，其将预训练的检索器与预训练的序列到序列模型相结合，通过端到端的微调，以更具可解释性和模块化的方式生成输出。早期的 RAG 技术侧重于模型的直接优化，例如采用密集通道检索[53]并对检索器与生成器进行同步的端到端微调[54]。

随着大语言模型（LLM）时代的到来，RAG 的内涵也随之扩展。其当前广泛的定义是：在生成文本时，首先从庞大的文档语料库中检索与输入相关的信息，随后利用这些检索到的信息辅助 LLM 生成文本，从而显著提升模型的理解能力与预测质量。这种方法使得开发者无需为每个特定任务重新训练整个模型，仅需附加一个外部知识库即可为模型提供动态、相关的信息支持。

RAG 的回答过程可概括为两个核心步骤：检索阶段与生成阶段[55]。

检索阶段：首先为外部数据构建索引，其流程包括将原始数据转化为纯文本、对文本进行适当的分割，并利用编码模型将文本单元转化为向量。随后，根据相似度计算（如余弦相似度）为输入查询检索最相关的文档片段。

生成阶段：将检索到的相关上下文与原始输入组合，形成一个新的、信息增强的提示，输入到语言模型中，由模型基于此进行最终预测。

基于上述通用范式，研究者在数据源的构成与利用方式上进行了深入探索，主要分为基于结构化数据和非结构化数据两条技术路线。

在结构化数据方面，最受关注的便是以知识图谱（Knowledge Graphs, KGs） 的形式为 LLM 提供外部知识，以此提高模型推理的可解释性。相关研究主要分为两类：一类建议在预训练阶段将知识图谱纳入 LLM，帮助模型从 KG 中学习结构化知识。例如，KG-BART 通过修改标准 BART 架构，在其中加入能处理和集成知识图谱嵌入的组件，使模型生成的句子更符合逻辑与常识[56]；Yang 等[57]提出在训练中让模型直接从文本和知识图谱中学习，通过更改编码器架构与训练任务，利用整合知识编码器综合处理文本和实体嵌入。另一类研究则在推理阶段从 KGs 中检索相关知识，作为外部信息扩展输入而无需重新训练。例如，KAPING[58]从知识图谱中检索相关事实并将其整合到提示中；Andrus 等[59]提出从文档中提取实体构建 KG，并将相关问题三元组转换为自然语言句子以创建信息提示；Wang 等[60]则提出了一个将 LLM 与多种知识图谱连接的框架，让 LLM 能生成访问 KG 的代码逻辑，从而根据检索到的实体知识回答复杂查询。

在非结构化数据方面，由于构建高质量 KG 需耗费大量人力，且在表示复杂句间逻辑关系时面临挑战，研究者广泛采用向量嵌入（Vector Embedding） 技术来经济高效地表示和检索非结构化文本。该技术将文本等对象映射为多维空间中的向量，使得语义相似的内容在向量空间中位置接近，进而可通过余弦相似性等方式进行量化检索。与依赖固定模式的知识图谱相比，向量相似性搜索在处理非结构化文本和揭示隐含语义联系方面展现出独特优势。例如，Lazaridou 等[61]探讨了利用互联网作为知识库，通过检索、切分文档并结合 LLM 生成答案；Peng 等[62]提出的 LLM 增强器利用相似性搜索从维基百科检索事实知识，显著提高了答案的真实性；He 等[63]将维基百科作为外部知识库，应用余弦相似性选择与查询最相似的段落，在常识推理和时间推理任务中证明了该方法的优越性；Ram 等[64]展示了基于上下文检索增强语言模型在开放领域问答任务中的有效性；Ma 等[65]则提出通过查询重写来弥合输入文本与检索知识之间的差距，进一步提高了检索增强型 LLM 的性能。

2.4.3 合同解析的新范式

基于上述技术背景，合同智能解析正在形成以提示学习和知识增强为核心的新范式。

在提示学习方面，研究者通过精心设计的指令引导大模型扮演"合同审查专家"的角色。从简单的零样本提示到思维链（Chain-of-Thought）[46]、思维树（Tree-of-Thoughts）[48]等复杂提示策略，显著提升了大模型在合同解析任务中的推理能力。Sun 等人[66]提出的 CARP 策略通过提示工程引导模型进行逐步推理，为复杂合同条款的解析提供了新思路。

在知识增强方面，检索增强生成（RAG）技术通过构建合同领域的专业知识库（包括法律法规、判例、标准合同范本等），为大模型提供准确、及时的外部知识支持。具体而言，可结合结构化知识（如法律领域知识图谱）和非结构化知识（如合同文本向量库）两种形式。RAG 通过检索和生成两个核心阶段，将领域知识动态融入生成过程，有效缓解了模型的幻觉问题，使生成结果具备可靠的法律依据和更强的可解释性。

2.4.4 合同风险识别的增强框架

基于前述新范式，本研究旨在构建一个面向商业合同领域的、基于大语言模型 API 的风险识别框架。该框架的核心思想是：将提示工程作为“方向盘”，引导模型的推理逻辑；将 RAG 技术作为“知识导航”，提供实时准确的专业信息，最终

实现对合同风险的精准、可信识别。

框架的核心运作机制如下：

1.多源知识检索：框架首先从一个专业构建的商业合同知识库中进行检索。该知识库是系统可靠性的基石，融合了两种形式的知识：（1）非结构化文本：包括法律法规、标准合同范本及行业规范等。这些文本通过向量嵌入技术进行语义表示，支持高效的相似性检索，是本框架知识库的主要组成部分。（2）结构化知识：可引入商业合同知识图谱概念，包含如“买方”、“卖方”、“违约责任”等实体及其相互关系，作为向量检索的有益补充，以进一步增强推理的逻辑性。当输入待审查的合同条款时，系统自动从知识库中检索最相关的法律条文或规范条款。

2.思维链引导的生成：在生成阶段，框架将检索到的权威知识与经过精心设计的提示词（内含“风险识别-依据查找-影响分析”的思维链指令）以及原合同条款进行组合，形成一个信息增强的提示，通过 API 输入至大语言模型。模型基于此进行推理，确保其输出的风险点、法律依据和影响分析均建立在可验证的外部知识之上。

本框架通过知识增强的方式，在保持大语言模型强大推理能力的同时，有效确保了专业知识的准确性与时效性，为商业合同风险识别提供了一条可靠的技术路径。工业界的初步实践（如 e 签宝、LawGeex 等平台）已印证了这一方向的可行性，预示着知识驱动、用户可信任的智能合同解析是未来的明确趋势。本研究将在此框架下进行具体的系统实现与验证。

2.5 研究现状总结与本课题的提出

综上所述，合同关键条款解析技术历经了从基于规则和传统机器学习的浅层分类，到基于深度学习的语义理解，再到基于预训练模型的精准要素抽取的演进过程，并正在迈向基于大语言模型的深度理解与生成的新范式。

然而，现有研究仍存在以下不足：

（1）领域知识融合不足：多数方法依赖于模型从训练数据中隐式学习法律知识，缺乏显式、可控的领域知识引导机制，导致结果的可解释性差且易产生幻觉。

（2）长上下文处理能力有限：商务合同篇幅长、结构复杂，现有方法在理解跨条款的远距离依赖关系上仍面临挑战。

（3）标准化与系统化框架缺失：如何将提示工程、RAG 与大模型高效结合，构建一个端到端的商务合同关键条款智能解析系统，仍需深入的探索与实践。

因此，本课题正是在此背景下提出。 本研究将基于前述所构建的增强框架，直面上述挑战，致力于探索并实现一个知识可信、逻辑严谨、系统化的商业合同关键条款解析方案，以推动大语言模型在专业风险管理中的有效应用。

（三）研究的主要内容、预期目标与创新点：

本课题旨在研究基于大语言模型与检索增强生成技术的商务合同关键条款智能解析系统。通过构建法律领域知识库，并结合动态提示词工程，探索一条能够深度融合外部知识、有效处理长文档、并输出可解释解析结果的技术路径，以应对当前合同审查智能化进程中的核心挑战。

1. 主要内容

本研究旨在设计并实现一个基于知识增强语言模型的商务合同关键条款智能解析与风险识别系统。系统将采用分层架构，具体研究内容如下：

（1）多模态合同文档智能处理模块：

开发统一的文档解析接口，支持处理 Word、PDF 及 JPG/PNG 扫描件等多种格

式的合同文件。

集成 OCR（光学字符识别）技术，实现对中英文混合合同扫描件的精准文本提取，为后续分析提供高质量的纯文本数据。

（2）领域知识增强的合同解析核心引擎：

双路知识库构建：建立包含 MySQL 关系型数据库（存储合同元数据与用户数据）和 Neo4j 图数据库（构建以《民法典》合同编为核心的领域知识图谱）的双重知识存储体系。

检索增强生成（RAG）流程实现：在解析合同时，系统将从向量化存储的合同范本、法规以及知识图谱中同步检索相关知识，动态增强输入至大语言模型（DeepSeek-R1）的提示词（Prompt），确保解析过程有据可依。

关键信息与风险智能识别：基于精心设计的 Prompt，引导大模型完成合同类型判断、关键条款（当事人、金额、期限等）提取、风险预警、SWOT 分析等一系列复杂任务。

（3）功能集成与可视化应用平台：

采用 React+Next.js 前端框架与 FastAPI 后端框架，开发一个用户友好的 Web 应用。

实现合同分析小助手、风险可视化报告（含雷达图等）、知识图谱交互式查询等功能界面，将分析结果以结构化和可视化的形式直观呈现给用户。

2.预期目标

（1）构建一个端到端的自动化系统原型：成功交付一个能够从文档上传到报告生成全流程自动化的系统原型，验证基于大模型 API 构建轻量级专业应用的可行性。

（2）实现高准确率的结构化信息抽取：系统对合同中“当事人”、“标的金额”、“履行期限”、“违约责任”等关键条款的提取准确率预期达到 90%以上，输出为标准化的 JSON 数据。

（3）生成具备法律依据的风险分析报告：通过 RAG 技术，确保系统提出的每一个风险点都尽可能引用相关的法律条文或合同范本依据，生成内容可靠、可直接辅助决策的可视化风险报告。

（4）完成系统集成与效果验证：完成前后端所有模块的集成，并通过真实或仿真的商务合同数据对系统的实用性、稳定性和分析效果进行综合测试与评估。

3.创新点

（1）技术集成创新：构建了“大模型 API + 双路知识库 + 提示工程”的轻量化技术范式：本研究不追求昂贵的模型微调，而是创新性地将通用大模型（DeepSeek）、向量数据库（用于非结构化文本检索）和知识图谱（Neo4j，用于结构化知识查询）进行高效集成。这种“参数化模型+非参数化知识”的混合架构，以较低成本实现了专业领域知识的可靠注入，为中小企业应用大模型提供了可复用的实践样板。

（2）方法应用创新：实现了面向合同风险的“思维链提示+RAG”协同增强机制：将提示工程从简单的问答提升到复杂的推理任务。通过设计“风险识别-依据查找-影响分析”的思维链提示，系统性地引导大模型进行逻辑推理；同时，利用 RAG 实时提供法律条文作为推理依据，这不仅有效缓解了模型的“幻觉”问题，更使得整个分析过程逻辑严谨、结果可解释、依据可溯源。

（3）成果形式创新：交付了一个集“解析、分析、可视化”于一体的一站式应用平台：突破了以往研究多为算法模型的局限，本研究的最终成果是一个功能完备的软件系统。它创造性地将合同解析、知识图谱探索、多维度风险可视化（SWOT、

雷达图） 等功能整合在统一平台中，为用户提供了从合同理解到风险洞察的闭环体验，极大地提升了研究成果的实用价值与应用潜力。

（四）研究思路、研究方法与研究计划：

1. 研究思路

本研究遵循“问题导向、理论支撑、技术集成、系统实现、效果验证”的总体思路，具体研究思路与初步技术路线如图所示。首先，通过梳理商务合同管理现状与现有技术的不足，明确核心研究问题：如何低成本、高效率地构建一个可靠、可用的商务合同智能解析系统。其次，以检索增强生成（RAG） 和提示工程为核心理论，设计一个将通用大语言模型与领域知识相结合的增强框架。在此基础上，采用模块化设计与敏捷开发的方法，依次完成文档处理、知识库构建、核心解析引擎及前端应用平台的开发。最后，通过测试用例与对比实验，对系统的功能完备性、解析准确性与实用性进行综合评估，验证本技术路线的有效性与创新性。

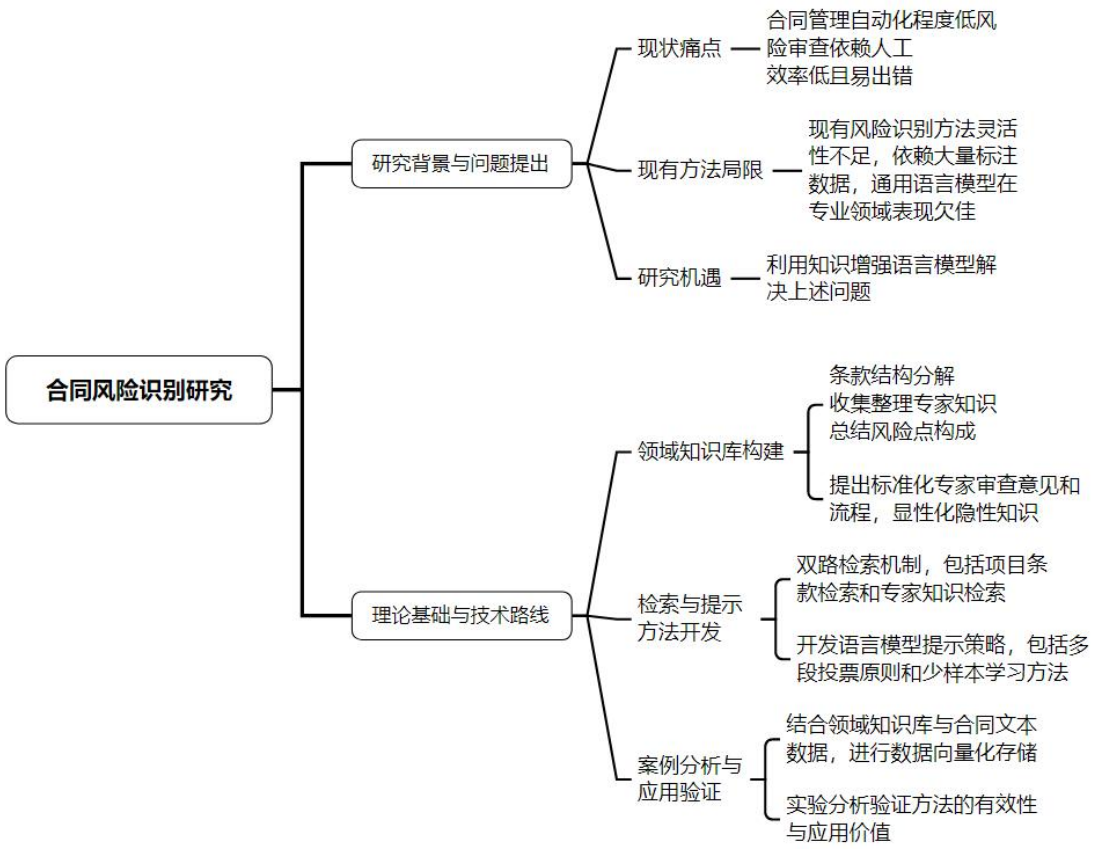

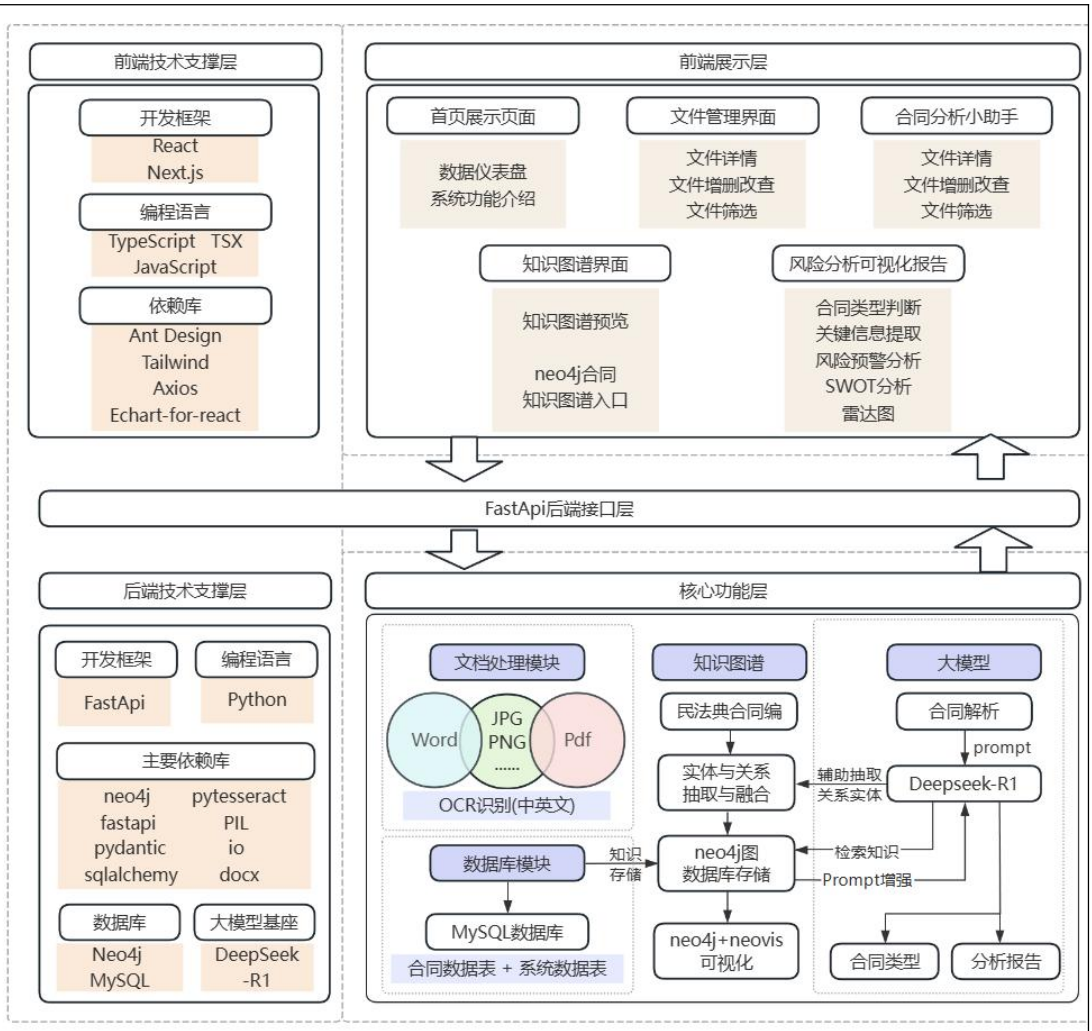

2. 研究方法

本研究将综合运用以下研究方法：

文献研究法：系统梳理国内外关于合同智能解析、大语言模型应用、RAG 技术及知识图谱构建等方面的学术文献与业界报告，为本研究提供坚实的理论基础与技术借鉴，确保研究方案的前沿性与科学性。

原型系统法：本研究的核心方法是设计与实现一个可工作的软件系统原型。通过前后端分离的架构（React+FastAPI），将理论框架转化为具体应用，并在开发过程中采用模块化设计，逐一攻克文档解析、知识检索、提示构建等关键技术难点。

案例分析与实验法：

案例研究：收集或构造一批具有代表性的商务合同（如采购合同、服务协议、技术开发合同等）作为测试案例，覆盖不同模板、格式及风险类型。

实验评估：利用这些案例对系统进行功能测试与性能评估。通过设定关键条款抽取的准确率、召回率，以及风险识别结果的合理性与依据充分性等量化指标，对系统效果进行客观评价，并与基线方法（如无知识增强的纯 Prompt 方法）进行对比分析。

3. 研究计划

第一阶段：文献调研与方案设计

任务：继续研读相关文献，明确技术选型；系统性地进行合同条款结构分解、专家知识收集与整理，形成风险点构成总结与专家审查流程；完成系统整体架构与

各模块的详细设计；准备开发环境。

预计产出：系统详细设计说明书、技术可行性报告。

第二阶段：系统核心模块开发

任务：完成后端文档处理模块（OCR 集成、文本解析）和数据库设计（MySQL, Neo4j），完成领域知识库的初步构建与数据注入。实现核心的 RAG 检索流程与大模型 API 调用接口；完成关键 Prompt 模板（用于信息抽取、风险分析等）的设计与初步调试。开发 FastAPI 后端核心业务接口；完成前端主框架及文件管理、分析报告展示等核心页面。

预计产出：系统核心模块代码、可运行的初级原型、初步构建的领域知识库。

第三阶段：系统集成、测试与优化

任务：完成前后端全面联调；实现所有功能界面；利用测试案例集进行系统测试，根据结果优化 Prompt、调整检索策略、修复 Bug。

预计产出：一个功能完整、运行稳定的系统原型、测试报告、优化记录。

第四阶段：论文撰写与答辩准备

任务：系统总结研究过程与成果，撰写毕业论文；整理所有代码、数据与文档准备答辩材料。

预计产出：完整毕业论文、答辩 PPT 及相关材料。

参考文献：

[1] 刘晓明,李丞正旭,吴少聪,等.文本分类算法及其应用场景研究综述[J].计算机学报,2024,47(06):1244-1287.

[2] Xiaodan Zhu, Parinaz Sobhani, and Hongyu Guo. 2015. Long short-term memory over recursive structures. In Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37 (ICML'15). JMLR.org, 1604–1612.

[3] Chen, J., Gong, Z. & Liu, W. A Dirichlet process biterm-based mixture model for short text stream clustering. Appl Intell 50, 1609–1619 (2020).

[4] Scott S, Matwin S. Feature engineering for text classification[C]//Proceedings of the 16th International Conference on Machine Learning (ICML 1999). Bled, Slovenia, 1999: 379-388.

[5] Sebastiani F. Machine learning in automated text categorization[J]. ACM Computing Surveys, 2002, 34(1): 1-47.

[6] Zhang Y, Jin R, Zhou Z H. Understanding bag-of-words model: A statistical framework[J]. International Journal of Machine Learning and Cybernetics, 2010, 1(1): 43-52.

[7] Salton G, Buckley C. Term-weighting approaches in automatic text retrieval[J]. Information Processing & Management, 1988, 24(5): 513-523.

[8] Maron M E. Automatic indexing: An experimental inquiry[J]. Journal of the ACM, 1961, 8(3): 404-417.

[9] Altman N S. An introduction to kernel and nearest-neighbor nonparametric regression[J]. The American Statistician, 1992, 46(3): 175-185.

[10] Joachims T. Text categorization with support vector machines: Learning with many relevant features[C]//Proceedings of the 10th European Conference on Machine Learning. Lecture Notes in Computer Science: Volume 1398 Machine Learni

ng: ECML-98. Chemnitz, Germany, 1998: 137-142.
[11] Gao X, Singh M P, Mehra P. Mining business contracts for service exceptio ns[J]. IEEE Transactions on Services Computing, 2011, 5(3): 333-344.
[12] Ilias Chalkidis, Ion Androutsopoulos, and Achilleas Michos. 2017. Extracting contract elements. In Proceedings of the 16th edition of the International Confer ence on Articial Intelligence and Law (ICAIL '17). Association for Computing Ma chinery, New York, NY, USA, 19–28.
[13] Lippi, M., Pałka, P., Contissa, G. et al. CLAUDETTE: an automated detecto r of potentially unfair clauses in online terms of service. Artif Intell Law 27, 117 –139 (2019).
[14] Ghosal D, Akhtar M S, Chauhan D S, et al. Contextual inter-modal attention for multi-modal sentiment analysis[C]//Proceedings of the 2018 Conference on E mpirical Methods in Natural Language Processing. Brussels, Belgium, 2018: 3454-3466.
[15] Kim Y. Convolutional neural networks for sentence classification[C]//Proceedi ngs of the 2014 Conference on Empirical Methods in Natural Language Processin g. Doha, Qatar: Association for Computational Linguistics, 2014: 1746-1754.
[16] Lai S, Xu L, Liu K, et al. Recurrent convolutional neural networks for text classification[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2 015, 29(1).
[17] 彭玉青, 宋初柏, 闫倩, 等. 基于VDCNN与LSTM混合模型的中文文本分类研究[J]. 计算机工程, 2018, 44(11): 190-196.
[18] 韩涛, 尹伟石, 方明. 基于卷积神经网络和XGBoost的情感分析模型[J]. 复旦学报（自然科学版）, 2019, 58(5): 560-564.
[19] 张虎, 王鑫, 王冲, 等.面向法律裁判文书的法条推荐方法[J]. 计算机科学,201 9, 46 (09): 211-215.
[20] 王文广, 陈运文, 蔡华, 等.基于混合深度神经网络模型的司法文书智能化处理 [J]. 清华大学学报(自然科学版),2019, 59 (07): 505-511.
[21] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[C]//Advances in Neural Information Process ing Systems 26 (NIPS 2013). Lake Tahoe, USA, 2013: 3111-3119.
[22] Ilic S, Marrese-Taylor E, Balazs J A, et al. Deep contextualized word repres entations for detecting sarcasm and irony[C]//Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis (WASSA@EMNLP 2018). Brussels, Belgium, 2018: 2-7.
[23] Dai Z, Yang Z, Yang Y, et al. Transformer-xl: Attentive language models be yond a fixedlength context[C]//Proceedings of the 57th Annual Meeting of the As sociation for Computational Linguistics. Florence,Italy. ACL, 2019: 2978-2988.
[24] Wang Z, Song H, Ren Z, et al. Cross-domain contract element extraction wi th a bi-directional feedback clause-element relation network[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Inf ormation Retrieval. 2021: 1003-1012.
[25] 朱鑫海.基于RoBERTa和词汇增强的合同文本命名实体识别研究[D].东北石油大学,2022.

[26] Elwany E, Moore D, Oberoi G.Bert goes to law school: Quantifying the co mpetitive advantage of access to large legal corpora in contract understanding[J]. arXiv preprint arXiv:.00473,2019.
[27] Zhao W X, Zhou K, Li J, et al. A Survey of Large Language Models[J]. ar Xiv Preprint arXiv:2303.18223.
[28] Huang Q, Tao M, An Z, et al. Lawyer LLaMA Technical Report[J]. arXiv P reprint arXiv:2305.15062.
[29] Cui J, Li Z, Yan Y, et al. Chatlaw: Open-Source Legal Large Language Mo del with Integrated External Knowledge Bases[J]. arXiv Preprint arXiv:2306.1609 2.
[30] Ul Hassan F, Le T, Lv X. Addressing Legal and Contractual Matters in Con struction Using Natural Language Processing: A Critical Review[J]. Journal of Co nstruction Engineering and Management, 2021, 147(9): 03121004.
[31] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language ge neration[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
[32] Huang L, Yu W, Ma W, et al. A Survey on Hallucination in Large Languag e Models: Principles, Taxonomy, Challenges, and Open Questions: arXiv:2311.052 32.
[33] Feng Z, Ma W, Yu W, et al. Trends in Integration of Knowledge and Large Language Models: A Survey and Taxonomy of Methods, Benchmarks, and Appli cations: arXiv:2311.05876.
[34] Sinitsin A, Plokhotnyuk V, Pyrkin D, et al. Editable neural networks[J]. arXi v preprint arXiv:2004.00345, 2020.
[35] De Cao N, Aziz W, Titov I. Editing Factual Knowledge in Language Model s[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Lang uage Processing, 2021: 6491-6506.
[36] Meng K, Bau D, Andonian A, et al. Locating and Editing Factual Associatio ns in GPT: arXiv:2202.05262.
[37] Dai D, Dong L, Hao Y, et al. Knowledge Neurons in Pretrained Transformer s: arXiv:2104.08696.
[38] Mitchell E, Lin C, Bosselut A, et al. Fast Model Editing at Scale: arXiv:211 0.11309.
[39] Huang Q, Tao M, An Z, et al. Lawyer LLaMA Technical Report[J]. arXiv P reprint arXiv:2305.15062.
[40] Cui J, Li Z, Yan Y, et al. Chatlaw: Open-Source Legal Large Language Mo del with Integrated External Knowledge Bases[J]. arXiv Preprint arXiv:2306.1609 2.
[41] Mitchell E, Lin C, Bosselut A, et al. Memory-based model editing at scale [C]. International Conference on Machine Learning. PMLR, 2022: 15817-15831.
[42] Zhong Z, Wu Z, Manning C, et al. MQuAKE: Assessing Knowledge Editing in Language Models via Multi-Hop Questions[C]. Proceedings of the 2023 Confe rence on Empirical Methods in Natural Language Processing, 2023: 15686–1570 2.
[43] Zheng C, Li L, Dong Q, et al. Can We Edit Factual Knowledge by In-Cont

ext Learning?[C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 4862–4876.
[44] Huang Z, Shen Y, Zhang X, et al. Transformer-Patcher: One Mistake worth One Neuron[J]. arXiv preprint arXiv:2301.09785, 2023.
[45] Dong Q, Dai D, Song Y, et al. Calibrating Factual Knowledge in Pretrained Language Models: arXiv:2210.03329.
[46] Wei J, Wang X, Schuurmans D, et al. Chain-of-Thought Prompting Elicits R easoning in Large Language Models: arXiv:2201.11903.
[47] Kojima T, Gu S S, Reid M, et al. Large Language Models Are Zero-Shot R easoners: arXiv:2205.11916.
[48] Yao S, Yu D, Zhao J, et al. Tree of Thoughts: Deliberate Problem Solving with Large Language Models: arXiv:2305.10601.
[49] Wang X, Wei J, Schuurmans D, et al. Self-consistency improves chain of th ought reasoning in language models[J]. arXiv preprint arXiv:2203.11171, 2022.
[50] Besta M, Blach N, Kubicek A, et al. Graph of Thoughts: Solving Elaborate Problems with Large Language Models: arXiv:2308.09687.
[51] Zhou D, Schärli N, Hou L, et al. Least-to-most prompting enables complex reasoning in large language models[J]. arXiv preprint arXiv:2205.10625, 2022.
[52] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Know ledge-Intensive NLP Tasks: arXiv:2005.11401.
[53] Karpukhin V, Oguz B, Min S, et al. Dense Passage Retrieval for Open-Dom ain Question Answering[C]. Proceedings of the 2020 Conference on Empirical Me thods in Natural Language Processing, 2020: 6769–6781.
[54] Izacard G, Lewis P, Lomeli M, et al. Few-Shot Learning with Retrieval Aug mented Language Models[J]. arXiv Preprint arXiv:2208.03299.
[55] Liu Y, Wan Y, He L, et al. KG-BART: Knowledge Graph-Augmented BART for Generative Commonsense Reasoning[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(7): 6418–6425.
[56] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large lan guage models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023.
[57] Yang L, Chen H, Li Z, et al. ChatGPT Is Not Enough: Enhancing Large La nguage Models with Knowledge Graphs for Fact-Aware Language Modeling: arXi v:2306.11489.
[58] Chalkidis I, Jana A, Hartung D, et al. LexGLUE: A Benchmark Dataset for Legal Language Understanding in English[C]. Proceedings of the 60th Annual Me eting of the Association for Computational Linguistics, 2022(1): 4310–4330.
[59] Andrus B R, Nasiri Y, Cui S, et al. Enhanced Story Comprehension for Lar ge Language Models through Dynamic Document-Based Knowledge Graphs[J]. Pr oceedings of the AAAI Conference on Artificial Intelligence, 2022, 36(10): 10436 –10444.
[60] Wang X, Yang Q, Qiu Y, et al. KnowledGPT: Enhancing Large Language M odels with Retrieval and Storage Access on Knowledge Bases: arXiv:2308.1176.
[61] Lazaridou A, Gribovskaya E, Stokowiec W, et al. Internet-Augmented Langua ge Models through Few-Shot Prompting for Open-Domain Question Answering: ar

Xiv:2203.05115.
[62] Peng B, Galley M, He P, et al. Check Your Facts and Try Again: Improvin g Large Language Models with External Knowledge and Automated Feedback: ar Xiv:2302.12813.
[63] He H, Zhang H, Roth D. Rethinking with Retrieval: Faithful Large Languag e Model Inference: arXiv:2301.00303.
[64] Ram O, Levine Y, Dalmedigos I, et al. In-Context Retrieval-Augmented Lan guage Models[J]. Transactions of the Association for Computational Linguistics, 2 023, 11: 1316–1331.
[65] Ma X, Gong Y, He P, et al. Query Rewriting for Retrieval-Augmented Large Language Models[J]. arXiv preprint arXiv:2305.14283, 2023.
[66] Sun X, Li X, Li J, et al. Text classification via large language models[J]. ar Xiv preprint arXiv:2305.08377, 2023.

指导教师意见（是否同意开题）：

指导教师：
时间：

学院或专业审核意见（明确“同意开题”、“不同意开题”或“修改后开题”）：

审核负责人：
审核时间：